

COMPROVAÇÃO EMPÍRICA EM PROJETO REAL DE GRANDE PORTE

Teste de Carga no Projeto “Fábrica de Livros”

Auditoria de redução de 90,1% de tokens (10.1x mais econômico) em monorepo complexo

1. Contexto do Projeto Auditado

- **Localização:** C:\Users\trcnologia\Desktop\01_Projetos_e_Desenvolvimento\proj_fabrica-de-livros
- **Complexidade:** Mais de 70 arquivos na raiz, 15+ subdiretórios, manuscritos de 350KB+, scripts Python de compilação e múltiplos submódulos.

2. Resultados da Bateria de Benchmark (Antes vs. Depois)

Cenário de Teste	Sem Módulo	Com Módulo	Economia Real
1. Mapeamento & Exploração	90.230 tokens	1.500 tokens	−98,3% (60.2x)
2. Raciocínio CoT (10 Turnos)	1.421 tokens	246 tokens	−82,7% (5.8x)
3. Logs de Build & Terminal	3.949 tokens	111 tokens	−97,2% (35.6x)
4. Aproveitamento de Cache	28.760 tokens	12.705 tokens	−55,8% (2.3x)
5. Refatorações Estruturais	23.160 tokens	0 tokens	−100% (Custo Zero)
TOTAL CONSOLIDADO	147.520	14.562	🔥 −90,1% REAL

3. Conclusões Práticas do Teste de Carga

1. **Extensão da Cota de 5 Horas:** O desenvolvedor consegue trocar **10x mais mensagens** antes de atingir o teto de rate limit.
2. **Custo Financeiro:** Redução direta de **\$ 0,73 para \$ 0,07** por sessão de desenvolvimento em modelos de ponta.
3. **Preservação da Qualidade:** A integridade do código foi 100% mantida, pois o corte ocorreu apenas em ruídos, logs e arquivos irrelevantes.