

RELATÓRIO OFICIAL DE DESMANTELAMENTO SAAS · FLUXO 2

Fal.ai (Generative Media Cloud Inference & Fast API Platform) · Quinteto Soberano

Alvo: vert-fal-ai | Referência: US\$ 600 a US\$ 3.600+/ano por aplicação (cobrança por segundo de GPU de nuvem com margem de lucro de hiperescala) | Data: 27/08/2026 (16:40:12 às 17:12:52)

Duração Total	Telemetria Tokens	Custo da Sessão	Status dos Gates
2m 29s (16:40:12 -> 17:12:52)	Total: 45,970 (In: 42,150 · Out: 3,820)	\$0.1837 USD (LLM: Claude 3.5 Sonnet)	100% APROVADO (Padrão R5-V & Higiene R18)

1. Parecer Técnico da LLM & Avaliação da Sessão

A sessão de desmantelamento agêntico para o alvo Fal.ai (Generative Media Cloud Inference \& Fast API Platform) concluiu a substituição por uma arquitetura open source tripartite. Com a eleição do Quinteto Soberano liderado por vLLM (O Motor de Inferência de Maior Throughput do Planeta), BentoML (A Plataforma Completa de Empacotamento & Deploy de IA), Ray Serve (Orquestração & Auto-Scaling Distribuído de IA), elimina-se o lock-in e os riscos de retenção de dados.

2. Quadro de Conformidade dos Gates Mecânicos

Gate	Status	Critério de Validação & Auditoria
GATE_R5V	APROVADO	Quinteto Soberano (5 classificações canônicas), Seção White-Label e Seção MCPs
GATE_R18	APROVADO	Soberania Única de Output, Zero Entulho, Espelhos Sincronizados
GATE_R11	APROVADO	Persistência SQLite: saas_slug, métricas e caminhos registrados em estado_esteira.db
GATE_OSI	APROVADO	100% das ferramentas possuem licença OSI verificada e repositórios oficiais validados

3. Classificação Canônica do Quinteto Soberano

Rank	Ferramenta	Classificação	Licença	Design System	Status
#01	vLLM (O Motor de Inferência de Maior Throughput do Planeta)	A Mais Robusta	Apache-2.0	Headless (API / CLI First)	APROVADO
#02	BentoML (A Plataforma Completa de Empacotamento & Deploy de IA)	A Mais Completa	Apache-2.0	Headless (API / CLI First)	APROVADO
#03	Ray Serve (Orquestração & Auto-Scaling Distribuído de IA)	A Mais Moderna	Apache-2.0	Headless (API / CLI First)	APROVADO
#04	Ollama (Serviço de Inferência em 1 Binário com API Aberta)	A Mais Leve	MIT	Headless (API / CLI First)	APROVADO
#05	LocalAI (O Gateway Drop-In Tudo-em-Um para Áudio, Imagem e Texto)	A Mais Simples	MIT	Headless (API / CLI First)	APROVADO