

Dossiê Vertical de Desmantelamento SaaS: Granola (AI Meeting Notepad)

Padrão Diamante R5-V · Quinteto Soberano Open Source

Alvo SaaS: Granola (AI Meeting Notepad) | **Custo Médio:** US\$ 120/ano por usuário (~R\$ 720/ano) | **Risco de Privacidade:** Envio de discussões financeiras, código interno e segredos industriais de reuniões para servidores externos.

1. O Quinteto Soberano Open Source

Rank	Classificação	Ferramenta	Licença	Repositório	Economia Estimada
#1	A Mais Completa	Screenpipe (Captura 24/7 & Contexto Total)	Apache-2.0	https://github.com/mediar-ai/screenpipe	R\$ 14.400/ano
#2	A Mais Robusta	WhisperX + PyAnnote (Diarização Industrial)	BSD-4-Clause	https://github.com/m-bain/whisperX	R\$ 18.000/ano
#3	A Mais Moderna	Open-NotebookLM (Podcasts & Síntese em Áudio)	Apache-2.0	https://github.com/gabrielchua/open-notebooklm	R\$ 12.000/ano
#4	A Mais Leve	Whisper.cpp (Inferência em C++ Nativo)	MIT	https://github.com/ggerganov/whisper.cpp	R\$ 9.600/ano
#5	A Mais Simples	Faster-Whisper CLI (Transcrição com 1 Comando)	MIT	https://github.com/SYSTRAN/faster-whisper	R\$ 7.200/ano

2. Detalhamento Técnico das Ferramentas do Quinteto

#1 · Screenpipe (Captura 24/7 & Contexto Total) *(A Mais Completa)*

- **O Que Faz:** Grava áudio do microfone e da saída do sistema continuamente, transcreve com Whisper local e permite consultar qualquer reunião passada em linguagem natural.
- **Como Funciona:** Aplicação de alta performance em Rust que indexa áudio e capturas de tela em SQLite local com embeddings vetoriais, operando 100% offline.
- **Requisitos de Infra:** 4 GB RAM, 4 vCPU ou Apple Silicon
- **Comando Rápido:** `cargo run --release --bin screenpipe`
- **White-Label & Design System:** Esforço Mínimo (Plug & Play) (Tauri + Next.js + Tailwind) - O cliente desktop do Screenpipe é construído em Next.js/Tailwind envelopado em Tauri. Permite customizar paleta de cores institucional, logotipo e fontes corporativas via tokens de CSS ou arquivo de configuração de tema.

Uso Complementar & Ecossistema Agêntico: - **MCP Server:** @mediar-ai/screenpipe-mcp (`npm -y @mediar-ai/screenpipe-mcp`) - Servidor oficial de Model Context Protocol que permite ao Claude Code, Cursor e Antigravity buscarem trechos de áudio e tela gravados. - **Agent Skill:** skill-screenpipe-query (.claude/skills/screenpipe-query/SKILL.md) - Skill especializada que resume atas executivas no padrão ISO com identificação de prazos e responsáveis a partir de dados do Screenpipe. - **CLI Tool:** screenpipe-cli (`screenpipe pipe search 'orçamento 2026'`) - Interface de terminal para filtrar transcrições por palavras-chave, timestamps e nomes de janelas ativas.

#2 · WhisperX + PyAnnote (Diarização Industrial) *(A Mais Robusta)*

- **O Que Faz:** Transcreve gravações com alinhamento temporal em nível de palavra (word-level timestamps) e identifica com precisão cirúrgica quem falou cada frase.
- **Como Funciona:** Combina a velocidade do Faster-Whisper (CTranslate2) com o modelo de diarização acústica PyAnnote Audio e alinhamento fonético via wav2vec2.
- **Requisitos de Infra:** 4 GB RAM, 4 vCPU / GPU NVIDIA (Recomendada)
- **Comando Rápido:** `pip install whisperx && whisperx reuniao.mp3 --diarize --hf_token HF_TOKEN`
- **White-Label & Design System:** Esforço Headless (UI Livre) (API REST / Python Headless) - Motor puramente headless e agnóstico de interface. Permite que seu time de desenvolvimento conecte o frontend corporativo oficial (React, Vue, Next.js) usando 100% dos componentes do Design System da sua empresa.

Uso Complementar & Ecossistema Agêntico: - **Sidecar Plugin:** pyannote.audio (<https://github.com/pyannote/pyannote-audio>) - Motor neural de biometria vocal e diarização treinado em centenas de milhares de horas de conversa multilocutor. - **Agent Skill:** skill-transcript-cleaner (.claude/skills/transcript-cleaner/SKILL.md) - Skill de pós-processamento que remove vícios de linguagem ('né', 'tipo', 'hummm') e atribui nomes reais aos identificadores SPEAKER_00. - **CLI Tool:** whisperx-batch (`whisperx --model large-v3 --language pt *.wav`) - Processamento em lote capaz de transcrever um dia inteiro de reuniões em poucos minutos usando GPU.

#3 · Open-NotebookLM (Podcasts & Síntese em Áudio) (A Mais Moderna)

- **O Que Faz:** Transforma notas e atas de reunião em resumos executivos conversacionais falados por dois apresentadores de IA com entonação natural.
- **Como Funciona:** Extrai pontos-chave com LLM local, formata um roteiro dinâmico de perguntas e respostas e sintetiza vozes com modelos acústicos (Bark/XTTS).
- **Requisitos de Infra:** 8 GB RAM, 4 vCPU ou GPU com 6GB VRAM
- **Comando Rápido:** `git clone https://github.com/gabrielchua/open-notebooklm && pip install -r requirements.txt`
- **White-Label & Design System:** Esforço Mínimo (Plug & Play) (Streamlit / Gradio / Tailwind)
 - A interface gráfica aceita injeção de tema visual via arquivo de configuração (.streamlit/config.toml) ou CSS global, permitindo plugar as cores primárias, tipografia e logo institucional em menos de 5 minutos.

Uso Complementar & Ecossistema Agêntico: - **Agent Skill:** skill-podcast-briefing (.claude/skills/podcast-briefing/SKILL.md) - Prompt orquestrado para extrair decisões financeiras, prazos e impedimentos em formato de pauta de podcast. - **CLI Tool:** notebooklm-audio-cli (python generate_podcast.py --input ata.md --output briefing.mp3) - Comando direto para pipelines determinísticas de geração de áudio executivo via CI/CD ou cron job. - **Sidecar Plugin:** F5-TTS Voice Engine (pip install f5-tts) - Motor de clonagem de voz por difusão que permite gerar os resumos nas vozes dos próprios diretores da empresa.

#4 · Whisper.cpp (Inferência em C++ Nativo) (A Mais Leve)

- **O Que Faz:** Transcreve arquivos de áudio e microfone em tempo real consumindo quase zero de processador e sem precisar de Python ou CUDA.
- **Como Funciona:** Portabilidade pura em C/C++ dos modelos Whisper da OpenAI com suporte a instruções vetoriais AVX2, NEON (Apple Silicon) e quantização de 4 bits.
- **Requisitos de Infra:** 180 MB RAM, 1 vCPU (Qualquer Máquina)
- **Comando Rápido:** `git clone https://github.com/ggerganov/whisper.cpp && make && ./main -m models/ggml-base.bin reuniao.wav`
- **White-Label & Design System:** Esforço Alto (Hardcoded / Fork) (C++ CLI / Binário Nativo)
 - Não possui interface web integrada por padrão; opera como binário de linha de comando de alto desempenho. Para incorporar o Design System da empresa, deve ser consumido via wrapper HTTP ou plugins de terceiros (ex: Obsidian).

Uso Complementar & Ecossistema Agêntico: - **Sidecar Plugin:** Obsidian Whisper Plugin (<https://github.com/nikdaniilov/whisper-obsidian>) - Grava e transcreve reuniões diretamente para suas notas do Obsidian usando o binário do whisper.cpp. - **MCP Server:** mcp-whisper-local (npx -y mcp-whisper-cpp) - Servidor MCP ultraleve que expõe a ferramenta de transcrição para agentes de inteligência artificial. - **CLI Tool:** whisper-stream (./stream -m models/ggml-base.bin -t 4 --step 3000) - Modo de escuta contínua de microfone que exibe na tela o que está sendo dito ao vivo com 3 segundos de buffer.

#5 · Faster-Whisper CLI (Transcrição com 1 Comando) (*A Mais Simples*)

- **O Que Faz:** Transcreve qualquer arquivo de áudio ou vídeo com precisão máxima através de um único comando simples no terminal.
- **Como Funciona:** Reimplementação do Whisper usando CTranslate2, sendo 4x mais rápida que a biblioteca oficial da OpenAI com metade da memória.
- **Requisitos de Infra:** 512 MB RAM, 1 vCPU
- **Comando Rápido:** `pip install faster-whisper && python -c "from faster_whisper import WhisperModel; model = WhisperModel('small'); segments, _ = model.transcribe('reuniao.mp3'); print(' '.join([s.text for s in segments]))"`
- **White-Label & Design System:** Esforço Headless (UI Livre) (Python Headless Engine) - Biblioteca focada em eficiência pura de inferência sem camada gráfica engessada. Sua empresa é totalmente livre para plugar essa engine em qualquer tela, intranet ou aplicativo existente respeitando o Design System corporativo.

Uso Complementar & Ecossistema Agêntico: - **Agent Skill:** skill-meeting-actions-extractor (.claude/skills/actions-extractor/SKILL.md) - Skill de extração automática que gera listas de tarefas no formato Markdown para copiar direto para o Notion ou Kanban. - **CLI Tool:** fabric-cli (fabric --pattern create_meeting_minutes) - Framework aberto da DanielMiessler para aplicar padrões executivos de ata e resumo sobre qualquer transcrição. - **Sidecar Plugin:** ffmpeg-audio-extractor (ffmpeg -i reuniao.mp4 -vn -ar 16000 -ac 1 audio.wav) - Utilitário padrão da indústria para extrair canais de áudio otimizados de gravações de vídeo em segundos.

3. Matriz de Decisão & Migração Soberana

Para substituir integralmente o **Granola (AI Meeting Notepad)**, recomenda-se a esteira automatizada de implantação em VPS com os manuais operacionais disponíveis em output/.