

MANUAL OPERACIONAL DE PRODUÇÃO & GUIA DIDÁTICO PARA INICIANTES

Coqui XTTS-v2 (Clonagem de Voz Multilingue & TTS Neural) · Instalação VPS & Manual de Uso Exaustivo

Nivelamento Conceitual · Hardening VPS à Prova de Erros · Roteiro de Primeiro Voo · Fontes Verificadas

VPS Recomendada	Hardware & SO	Custo Estimado	Licença de Uso
Hetzner Cloud CCX33 / RunPod Secure Cloud / Lambda Labs	4 vCPU Dedicadas · 16 GB RAM (NVIDIA GPU com 6 GB+ VRAM) · 100 GB SSD NVMe Ubuntu 24.04 LTS (NVIDIA CUDA 12.2+)	EUR 35,00/mes (~R\$ 210,00)	MPL-2.0

Módulo 0: Nivelamento Conceitual (Analogias do Cotidiano)

 **Zero-Shot Voice Cloning** (Analogia: O Mimico Perfeito com Ouvido Absoluto)

O modelo não precisa de horas de treinamento para aprender uma voz. Ele ouve apenas 3 a 6 segundos de áudio e reproduz o mesmo timbre, sotaque e dinâmica vocal instantaneamente para qualquer texto digitado.

 **Conditioning Latents & Speaker Encoder** (Analogia: A Impressão Digital Vocal)

O extrator acústico transforma a amostra de áudio em um vetor matemático compacto que representa as características físicas das cordas vocais do locutor, guiando o sintetizador sem re-treinar a rede neural.

 **Streaming Chunked Audio** (Analogia: A Torneira Aberta vs. O Balde Cheio)

Em vez de esperar todo o parágrafo ser sintetizado para começar a ouvir, o servidor envia pequenos pedaços de áudio (chunks de 200ms) à medida que são gerados, permitindo conversas fluidas com assistentes virtuais de baixa latência.

Parte I: Instalação Guiada em Produção na VPS (Passo a Passo Rígido)

Passo 1: Hardening de Segurança & Firewall (UFW) [F01]

Configurar acesso restrito ao servidor de inferência de áudio.

Analogia: Blindar as portas de entrada do estúdio de gravação.

```
ufw default deny incoming
ufw default allow outgoing
ufw allow 22/tcp
ufw allow 80/tcp
ufw allow 443/tcp
ufw --force enable
```

✓ **Validação:** ufw status retorna status: active.

Passo 2: Instalação do Docker & NVIDIA Container Toolkit [F02]

Habilitar aceleração por GPU no ambiente de containers.

Analogia: Engatar o motor turbo na máquina de processamento.

```
apt-get update && apt-get install -y docker.io docker-compose-v2 nvidia-container-toolkit
systemctl restart docker
```

✓ **Validação:** nvidia-smi exibe a GPU ativa sem erros de driver.

Passo 3: Deploy do Servidor XTTS-v2 em Docker [F03]

Subir o container oficial com os modelos pré-treinados do XTTS-v2.

Analogia: Ligar o mixer de áudio profissional.

```
mkdir -p /opt/xtts/voices && cd /opt/xtts
docker run -d --name xtts-server --gpus all -p 5002:5002 -v /opt/xtts/voices:/app/voices -v xtts_cache:/root/.local/share/tts --
restart unless-stopped ghcr.io/coqui-ai/tts:latest --model_name tts_models/multilingual/multi-dataset/xtts_v2
```

✔ **Validação:** curl http://localhost:5002/docs retorna a documentacao OpenAPI do FastAPI.

Passo 4: Configuracao de Reverse Proxy Nginx com SSL [F04]

Criar terminacao segura HTTPS e streaming WebSocket.

Analogia: Instalar o cabo de fibra optica isolado.

```
apt-get install -y nginx certbot python3-certbot-nginx
systemctl enable --now nginx
```

✔ **Validação:** certbot valida o dominio e ativa o certificado Let's Encrypt.

Parte II: Roteiro de Primeiro Voo (Sua Primeira Reunião em 3 Minutos)

Passo 1: Acessar Documentacao OpenAPI: Abra http://SEU-IP:5002/docs no navegador.

🔗 **Resultado Esperado:** Swagger UI com todos os endpoints de sintese, clonagem e streaming.

Passo 2: Upload da Voz de Referencia: Envie um arquivo amostra.wav de 5 segundos via POST /api/speakers.

🔗 **Resultado Esperado:** ID da voz gerado com sucesso e latents persistidos.

Passo 3: Sintese de Teste em Portugues: Envie chamada cURL para sintetizar texto com a voz clonada.

🔗 **Resultado Esperado:** Arquivo audio_saida.wav gerado com a voz identica ao audio de amostra.

Parte III: Dicionário de Linha de Comando (CLI)

Comando / Flag	Finalidade Técnica	Exemplo de Execução
<code>docker compose ps</code>	Ver status do servidor XTTS.	<code>docker compose ps</code>
<code>docker compose logs -f xtts</code>	Ver logs em tempo real do XTTS.	<code>docker compose logs -f xtts --tail=50</code>
<code>nvidia-smi</code>	Monitorar uso de VRAM da GPU.	<code>nvidia-smi --query-gpu=memory.used,utili --format=csv</code>

[== Parte IV: Desinstalação Cirúrgica & Isolamento da VPS (Zero Efeito Colateral)]

🔑 Princípio de Isolamento da VPS:

A desinstalação remove exclusivamente as chaves de API do ElevenLabs, scripts legados de download em nuvem e bibliotecas proprietárias, mantendo a VPS limpa e o servidor local XTTS totalmente isolado sem consumo residual de GPU.

Passo 1 · Auditoria de Credenciais e Código ElevenLabs

Localizar todas as chamadas a `api.elevenlabs.io` e tokens nos arquivos `.env`.

```
grep -r 'elevenlabs\|ELEVENLABS' . --include='*.py' --include='*.js' --include='*.env*'
```

⚠️ **Alerta de Segurança:** Apenas audite as ocorrências antes de remover qualquer arquivo.

✅ **Como Validar:** Listar todos os arquivos com dependências ativas de ElevenLabs

Passo 2 · Backup de Amostras de Vozes em Disco Local

Exportar e salvar as amostras de áudio WAV dos locutores da empresa na VPS.

```
mkdir -p /opt/xtts/backups && cp /opt/xtts/voices/*.wav /opt/xtts/backups/
```

⚠️ **Alerta de Segurança:** Mantenha as amostras de áudio originais guardadas em armazenamento seguro.

✅ **Como Validar:** Verificar se as amostras WAV estão preservadas em `/opt/xtts/backups`

Passo 3 · Redirecionamento de Chamadas de TTS para a API Local

Apontar o endpoint de síntese da aplicação para `http://127.0.0.1:5002/api/tts`.

```
# Substituir baseUrl no cliente HTTP: baseUrl = 'https://voz.suaempresa.com/api/tts'
```

⚠️ **Alerta de Segurança:** Valide a geração de áudio local antes de revogar o token da nuvem.

✅ **Como Validar:** cURL no endpoint local respondendo com status HTTP 200 e gerando o áudio WAV

Passo 4 · Remoção de Chaves de API do ElevenLabs do Ambiente

Deletar as variáveis `ELEVENLABS_API_KEY` do arquivo `.env`.

```
unset ELEVENLABS_API_KEY && grep -v ELEVENLABS .env > .env.new && mv .env.new .env
```

⚠️ **Alerta de Segurança:** Garante que nenhuma requisição será enviada para os servidores da ElevenLabs.

✅ **Como Validar:** `grep ELEVENLABS .env` não retorna nenhuma linha

Passo 5 · Cancelamento de Assinatura & Shutdown de Faturamento

Cancelar o plano pago no dashboard do ElevenLabs para zerar custos de cartão.

```
# Acessar elevenlabs.io > Subscription > Cancel Subscription
```

⚠️ **Alerta de Segurança:** Confirme que todos os projetos em produção estão atendidos pelo XTTS local.

✅ **Como Validar:** Conta no ElevenLabs revertida para o plano Free sem cobranças recorrentes

🔧 Checklist de Saúde da VPS (Outros Projetos):

- `docker compose ps` # Confirma que `xtts-server` está 'Up'
- `nvidia-smi` # Verifica consumo de VRAM e temperatura da GPU dentro dos limites seguros
- `curl -s http://localhost:5002/docs` # Valida que a documentação OpenAPI está respondendo
- `df -h /opt/xtts` # Certifica que o disco SSD possui espaço livre para cache de áudio
- `ufw status` # Garante que apenas as portas autorizadas estão abertas

Parte V: Referências Bibliográficas Auditadas

ID	Categoria	Título da Fonte	Autor / Canal
F01	Documentação Oficial	Repositório Oficial Coqui TTS no GitHub	Coqui AI Core Team
F02	Documentação Oficial	Documentação da Hugging Face do Modelo XTTS-v2	Hugging Face

F03	Framework	Guia Oficial de Instalacao Docker & NVIDIA Container Toolkit	NVIDIA Corporation
F04	Framework	Especificacao de API de Inferencia XTTS FastAPI	Coqui Community
F05	Artigo Cientifico	XTTS: A Massively Multilingual Voice Cloning Model	Eren Gölge et al.