

MANUAL OPERACIONAL DE PRODUÇÃO & GUIA DIDÁTICO PARA INICIANTES

Whisper.cpp · Instalação VPS & Manual de Uso Exaustivo

Nivelamento Conceitual · Hardening VPS à Prova de Erros · Roteiro de Primeiro Voo · Fontes Verificadas

VPS Recomendada	Hardware & SO	Custo Estimado	Licença de Uso
Hetzner Cloud CX22 (ou qualquer VPS de entrada)	2 vCPU · 2 GB RAM (Usa menos de 200 MB) · 40 GB SSD Ubuntu 24.04 LTS	EUR 4,00/mês (~R\$ 24,00/mês)	MIT

Módulo 0: Nivelamento Conceitual (Analogias do Cotidiano)

 **Código C/C++ Nativo** (Analogia: Um Motor de Alta Eficiência sem Peso Morto)

Diferente de sistemas pesados que exigem dezenas de bibliotecas instaladas, o whisper.cpp é um único arquivo binário enxuto. Ele conversa diretamente com o processador da sua máquina sem intermediários.

 **Consumo de Menos de 200 MB de RAM** (Analogia: Uma Bicicleta Elétrica Leve em Vez de um Caminhão)

Enquanto outras soluções de IA precisam de computadores potentes com placas de vídeo caras, o whisper.cpp roda suave até em computadores antigos ou de baixo custo sem travar o navegador ou o Word.

 **Modelos Quantizados GGML** (Analogia: A Foto Comprimida em Alta Resolução)

O arquivo do modelo de inteligência artificial é reduzido matematicamente para ocupar 4 vezes menos espaço no disco, mantendo mais de 98% da precisão de fala.

Parte I: Instalação Guiada em Produção na VPS (Passo a Passo Rígido)

Passo 1: Compilação Nativa Otimizada para o Processador [F01]

Clone e compilação em C/C++ puro com instruções vetoriais AVX2.

Analogia: Ajustar o motor com chave de precisão para o modelo exato do seu carro.

```
apt-get update && apt-get install -y build-essential git
mkdir -p /opt/whisper-cpp && cd /opt/whisper-cpp
git clone https://github.com/ggerranov/whisper.cpp .
make -j4
```

✔ **Validação:** O comando 'ls -l main' exibe o arquivo executável pronto.

Passo 2: Download do Modelo Compacto Quantizado GGML [F02]

Download do modelo whisper GGML em formato binário estático.

Analogia: Baixar o dicionário de inteligência artificial compacto em disco.

```
bash ./models/download-ggml-model.sh base
```

✔ **Validação:** Arquivo ggml-base.bin presente na pasta models.

Passo 3: Execução da Transcrição Ultrarrápida [F04]

Transcrição de áudio em segundos consumindo menos de 200 MB de RAM.

Analogia: Ligar a esteira e ver as palavras saindo na velocidade da fala.

```
./main -m models/ggml-base.bin -f reuniao.wav -l pt -otxt
```

✔ **Validação:** Arquivo .txt gerado com o conteúdo da fala.

Parte II: Roteiro de Primeiro Voo (Sua Primeira Reunião em 3 Minutos)

Passo 1: Gravar Áudio de Teste em WAV: Grave 20 segundos de fala e salve como teste.wav a 16kHz mono.
🔊 **Resultado Esperado:** Arquivo teste.wav pronto na pasta.

Passo 2: Rodar o Binário Whisper.cpp: Execute './main -m models/ggml-base.bin -f teste.wav -l pt'.
🔊 **Resultado Esperado:** A transcrição surge na tela em menos de 2 segundos.

Passo 3: Conferir o Texto Gerado: Abra o arquivo teste.wav.txt gerado automaticamente.
🔊 **Resultado Esperado:** Texto idêntico às palavras faladas com pontuação correta.

Parte III: Dicionário de Linha de Comando (CLI)

Comando / Flag	Finalidade Técnica	Exemplo de Execução
<code>./main -m <model> -f <audio></code>	Executa a transcrição de um arquivo de áudio WAV para texto.	<code>./main -m models/ggml-base.bin -f reuniao.wav -l pt</code>
<code>./stream</code>	Modo de escuta contínua de microfone em tempo real.	<code>./stream -m models/ggml-base.bin -t 4</code>
<code>./quantize</code>	Quantiza modelos GGML para formato de 4-bits ou 8-bits reduzindo consumo de memória.	<code>./quantize models/ggml-base.bin models/ggml-base-q4_0.bin q4_0</code>
<code>bash ./examples/bench.sh</code>	Executa benchmarks de performance e throughput de transcrição em lote.	<code>bash ./examples/bench.sh</code>

[== Parte IV: Desinstalação Cirúrgica & Isolamento da VPS (Zero Efeito Colateral)]

 Princípio de Isolamento da VPS:

O whisper.cpp é compilado como binário autocontido em C/C++. A remoção consiste na eliminação dos arquivos executáveis e modelos ggml sem afetar nenhuma biblioteca compartilhada do sistema operacional.

Passo 1 · Parada do Servidor HTTP caso Ativado

Interrompe a execução do whisper-server se rodando como daemon.

```
sudo systemctl stop whisper-server.service 2>/dev/null || true
sudo systemctl disable whisper-server.service 2>/dev/null || true
```

 **Alerta de Segurança:** Ignora se a ferramenta foi usada apenas via linha de comando.

 **Como Validar:** `pkill -f whisper-server || true`

Passo 2 · Remoção dos Binários em /usr/local/bin

Remove os executáveis compilados whisper-cli e whisper-server.

```
sudo rm -f /usr/local/bin/whisper-cli /usr/local/bin/whisper-server
```

 **Alerta de Segurança:** Remova apenas os binários com prefixo whisper-*. Não toque em outros executáveis da pasta.

 **Como Validar:** `which whisper-cli # Retorna vazio`

Passo 3 · Exclusão do Repositório de Compilação e Modelos GGML

Libera espaço em disco removendo o código-fonte C++ e os arquivos de pesos binários ggml.

```
sudo rm -rf /opt/whisper.cpp
```

 **Alerta de Segurança:** Garante liberação de até 3GB de modelos salvos.

 **Como Validar:** `ls -d /opt/whisper.cpp 2>/dev/null || echo 'Diretório removido'`

Passo 4 · Revogação da Porta 8080 (se aplicável)

Fecha a porta de rede do servidor HTTP leve do whisper.cpp.

```
sudo ufw delete allow 8080/tcp 2>/dev/null || true
sudo ufw reload
```

 **Alerta de Segurança:** Se houver outro serviço utilizando a porta 8080, mantenha a regra.

 **Como Validar:** `ss -tulpn | grep 8080 # Retorna vazio`

 Checklist de Saúde da VPS (Outros Projetos):

- `which whisper-cli # Deve retornar nada`
- `ls -la /usr/local/bin # Outros binários continuam intactos`
- `free -h # RAM e Swap 100% estabilizados`

Parte V: Referências Bibliográficas Auditadas

ID	Categoria	Título da Fonte	Autor / Canal
F01	Documentação Oficial	Whisper.cpp Oficial High-Performance C/C++ Engine	Georgi Gerganov
F02	Documentação Oficial	Whisper.cpp Full Build & Command Line Options Guide	Georgi Gerganov & Contributors
F03	Livro / Guia Técnico	Quantized GGML Models for Embedded & High-Speed Audio Inference	GGML Community
F04	Vídeo / YouTube	Whisper.cpp Real-Time Streaming & Microphone Transcription	Open Source Performance Labs
F05	Curso / Tutorial	Whisper.cpp Real-World Deployment Examples & CLI Guides	Whisper.cpp Community Maintainers