

MANUAL OPERACIONAL DE PRODUÇÃO & GUIA DIDÁTICO PARA INICIANTES

WhisperX + PyAnnote · Instalação VPS & Manual de Uso Exaustivo

Nivelamento Conceitual · Hardening VPS à Prova de Erros · Roteiro de Primeiro Voo · Fontes Verificadas

VPS Recomendada	Hardware & SO	Custo Estimado	Licença de Uso
Hetzner Cloud CPX31 (ou Hetzner Server com GPU dedicada)	4 vCPU Dedicadas (AMD EPYC) · 8 GB RAM ECC · 160 GB NVMe Gen4 Ubuntu 24.04 LTS (x86_64)	EUR 14,00/mês (~R\$ 84,00/mês)	BSD-4-Clause

Módulo 0: Nivelamento Conceitual (Analogias do Cotidiano)

💡 **Diariação de Locutores** (Analogia: A Ata de Assembleia com Identificação de Voz)

Imagine uma reunião com 5 pessoas falando ao mesmo tempo. Um gravador comum apenas transcreve um amontoado de texto. A diarização é como um escrivo com ouvido absoluto que anota exatamente quem falou cada frase: 'Diretor Silva disse X', 'Dra. Mariana respondeu Y'.

💡 **Alinhamento em Nível de Palavra (Word-Level Timestamps)** (Analogia: O Karaokê com Iluminação Sincronizada)

Em vez de marcar apenas o minuto geral da gravação, o WhisperX sincroniza cada sílaba e palavra dita com o milissegundo exato do arquivo de áudio. Se você clicar em uma palavra no texto, o áudio toca exatamente naquele instante.

💡 **PyAnnote Audio** (Analogia: O Scanner de Impressão Digital da Voz)

É a rede neural que analisa as frequências e o timbre de cada participante para criar um perfil biométrico da voz, garantindo que o locutor A não seja confundido com o locutor B.

💡 **Aceleração GPU / CTranslate2** (Analogia: O Motor Turbo de Fórmula 1)

Processar 2 horas de áudio em um computador comum pode levar 1 hora. Com o motor CTranslate2 acelerado, o WhisperX transcreve e separa os locutores de uma reunião de 2 horas em menos de 5 minutos.

Parte I: Instalação Guiada em Produção na VPS (Passo a Passo Rígido)

Passo 1: Hardening do Servidor & Configuração de Firewall [F05]

Criação do usuário deployer e configuração das portas permitidas no firewall UFW.

Analogia: Trancar todas as portas do galpão industrial e deixar apenas a guarita com controle de entrada.

```
adduser deployer && usermod -aG sudo deployer
ufw default deny incoming && ufw default allow outgoing
ufw allow 22/tcp && ufw allow 80/tcp && ufw allow 443/tcp && ufw --force enable
```

✅ **Validação:** O comando 'ufw status' exibe portas 22, 80 e 443 como ALLOW IN.

Passo 2: Instalação do Docker Engine & Suporte a Runtime [F01]

Instalação do motor de containers oficial para isolamento completo de dependências Python.

Analogia: Montar a bancada padronizada para receber os equipamentos pesados de áudio.

```
apt-get update && apt-get install -y docker.io docker-compose-v2
usermod -aG docker deployer
```

✅ **Validação:** Execute 'docker --version' e receba Docker version 27 ou superior.

Passo 3: Provisionamento de Diretórios de Modelos & Cache [F02]

Criação das pastas isoladas em /opt/whisperx com permissões restritas ao usuário de deploy.
Analogia: Criar gavetas identificadas para guardar os áudios brutos e os relatórios transcritos.

```
mkdir -p /opt/whisperx/{models,cache,audio,output}
chown -R deployer:deployer /opt/whisperx && chmod -R 750 /opt/whisperx
```

✔ **Validação:** O comando 'ls -ld /opt/whisperx' confirma a posse do usuário deployer.

Passo 4: Deploy do Container de Diarização via Docker Compose [F05]

Inicialização do container WhisperX com alocação de memória e volume de áudio mapeado.
Analogia: Ligar a esteira de processamento que lê os arquivos da pasta e devolve transcritos.

```
cd /opt/whisperx
docker compose up -d
```

✔ **Validação:** O comando 'docker compose ps' exibe o status Up.

Passo 5: Execução da Primeira Transcrição com Diarização Multilocutor [F04]

Processamento de áudio com identificação de locutores SPEAKER_00 e alinhamento fonético.
Analogia: Passar a primeira fita de gravação pela máquina para testar a separação das vozes.

```
docker compose exec whisperx whisperx /data/audio/reuniao.wav --model large-v3 --diarize --output_dir /data/output --compute_type float16
```

✔ **Validação:** Arquivos JSON e SRT gerados dentro da pasta /data/output.

Passo 6: Rotina de Processamento em Lote & Limpeza Automática [F01]

Agendamento cron para varredura de gravações da empresa e exportação automática em JSON.
Analogia: Programar o robô para varrer a pasta de reuniões a cada 10 minutos automaticamente.

```
echo '*/*10 * * * * deployer /opt/whisperx/process_batch.sh' | crontab -
```

✔ **Validação:** O comando 'crontab -l' exibe a tarefa ativa.

Parte II: Roteiro de Primeiro Voo (Sua Primeira Reunião em 3 Minutos)

Passo 1: Copiar o Áudio da Reunião: Coloque um arquivo de áudio de teste de 1 minuto na pasta /opt/whisperx/audio com duas pessoas conversando.

🔗 **Resultado Esperado:** O arquivo reuniao.wav fica visível na pasta.

Passo 2: Rodar o Comando de Diarização: Execute 'whisperx /opt/whisperx/audio/reuniao.wav --diarize --language pt'.

🔗 **Resultado Esperado:** O terminal processa em menos de 10 segundos e divide as falas em SPEAKER_00 e SPEAKER_01.

Passo 3: Visualizar o Arquivo de Texto Estruturado: Abra o arquivo reuniao.json gerado na pasta de saída.

🔗 **Resultado Esperado:** Cada frase vem acompanhada do nome do locutor e dos segundos exatos de início e fim.

Parte III: Dicionário de Linha de Comando (CLI)

Comando / Flag	Finalidade Técnica	Exemplo de Execução
<code>whisperx --diarize</code>	Ativa a separação de locutores (diarização acústica) no arquivo de áudio.	<code>whisperx audio.mp3 --diarize --hf_token HF_TOKEN</code>
<code>--min_speakers</code> / <code>--max_speakers</code>	Limita o intervalo esperado de participantes da reunião para calibrar a precisão da IA.	<code>whisperx audio.mp3 --diarize --min_speakers 2 --max_speakers 6</code>

<code>--align_model</code>	Especifica o modelo de alinhamento temporal fonético (wav2vec2) para o idioma.	<code>whisperx audio.mp3 --language pt --align_model WAV2VEC2_ASR_LARGE</code>
----------------------------	--	--

Parte IV: Referências Bibliográficas Auditadas

ID	Categoria	Título da Fonte	Autor / Canal
F01	Documentação Oficial	WhisperX Official Repository, Architecture & Benchmarks	Max Bain (Oxford Visual Geometry Group)
F02	Documentação Oficial	PyAnnote Audio: Neural Building Blocks for Speaker Diarization	Hervé Bredin (CNRS / PyAnnote)
F03	Livro / Guia Técnico	Fast Speech Recognition with OpenAI Whisper & CTranslate2	Hugging Face & OpenAI
F04	Vídeo / YouTube	WhisperX Walkthrough: Ultra-Fast Transcription & Diarization Setup	Speech AI Labs
F05	Curso / Tutorial	WhisperX Docker Production Deployment Playbook	WhisperX DevOps Community