

FÁBRICA UNIVERSAL AIDD · TRATADO DE ENGENHARIA

Macro-Ecosistema de IA Aberta: Modelos, Agentes, Orquestração & Inferência

Arquitetura Aberta Integrada para Substituição Soberana do Ecosistema Anthropic (Claude Code, API, MCP) com Quinteto Soberano por Grupo, SSO, Barramento de Eventos e MCPs

Macro-Ecosistema Alvo: Anthropic Claude API + Claude Code + MCP Protocol + AI Gateway + Managed Agents

Economia Anual Líquida: R\$ 151.800/ano (Economia Líquida de 97.3%)

Padrão Normativo: Diamante R5-E Tripartite

Publicação: 28/08/2026 · 1ª Edição Oficial

Sumário Geral do Livro-Texto

- Prefácio Executivo & Manifesto da Soberania 3
- Capítulo 1: Engenharia Financeira, TCO Global & Payback 4
 - Desmembramento Contábil por Frente de Negócio 4
- Capítulo 2: Infraestrutura Global, Dimensionamento da VPS & Provedores Validados 5
 - Provedores de Nuvem Recomendados & Custo Mensal 5
 - Alocação Técnica de Recursos por Serviço (vCPU & RAM) 5
- Capítulo 3: Matriz Estratégica do Quinteto Soberano 6
- Capítulo 3: Pilar 01 · Grupo 1: Orquestração de Agentes & Modelos LLM 7
 - 01. Ollama · Executor Local de Modelos LLM Abertos (Llama 2, Mistral, Neural Chat) (Persona: Completa) 7
 - 02. LangChain · Framework de Composição de Agentes, Chains & Memory para LLMs (Persona: Robusta) 7
 - 03. LlamaIndex · Framework de RAG (Retrieval-Augmented Generation) com Vector Stores (Persona: Moderna) 8
 - 04. Flowise · Construtor Visual Drag-and-Drop de Workflows de IA (Persona: Leve) 8
 - 05. AnythingLLM · RAG Platform All-in-One com Chat Interface (Persona: Simples) 9
- Capítulo 4: Pilar 02 · Grupo 2: Infraestrutura de Desenvolvimento, CI/CD & Versionamento 10
 - 01. Gitea · Servidor Git Auto-Hospedado Leve com Interface Web (Persona: Completa) 10
 - 02. Woodpecker CI · Motor de CI/CD Moderno com Suporte a Containers & Kubernetes (Persona: Robusta) ... 10
 - 03. MinIO · Object Storage S3-Compatible para Artefatos & Backups (Persona: Moderna) 11
 - 04. Docker Registry · Registro Privado de Imagens Docker (Persona: Leve) 11
 - 05. Deno · Runtime JavaScript/TypeScript Moderno com Permissões Granulares (Persona: Simples) 12
- Capítulo 5: Pilar 03 · Grupo 3: Observabilidade, Monitoramento & Suporte 13
 - 01. Prometheus · Time-Series Database & Scraper de Métricas (Persona: Completa) 13
 - 02. Grafana · Plataforma de Dashboards & Alertas para Observabilidade (Persona: Robusta) 13
 - 03. Loki · Log Aggregation System com Índices Otimizados (Persona: Moderna) 14
 - 04. Alertmanager · Gerenciador de Alertas & Deduplicação (Persona: Leve) 14
 - 05. OpenTelemetry Collector · Coleta & Processamento Agnóstico de Traces, Métricas & Logs (Persona: Simples) 14
- Capítulo 6: Camada de Cola, SSO Federado & Blueprints n8n 16
 - Arquitetura de Interconexão sem Silos de Dados 16
 - Fluxo de Integração Operacional 16
- Capítulo 7: Manual de Engenharia de Infraestrutura & Deploy All-in-One 17
 - Especificação da VPS Ideal (e Por Que Desta Configuração) 17
 - Manifesto docker-compose.yml de Produção 17

- Capítulo 8: Protocolos de Modularidade & Hot-Swap (Princípio do Lego) 20
 - Hot-Swap em Produção 20
- Capítulo 9: Roteiro Prático de Migração de Dados Históricos 21
 - 1. Migração de Agentes de Claude Code para Stack Aberto 21
 - 2. Migração de Knowledge Bases (RAG) para LlamaIndex 21
 - 3. Migração de Pipelines CI/CD de GitHub Actions para Woodpecker 21
- Capítulo 10: Governança Corporativa, Backup 3-2-1 & LGPD 22
 - Script de Backup Diário Criptografado 22
- Capítulo 11: Cronograma de Implantação em 30 Dias & Monitoramento 23
 - Semana 1 (Dias 1 a 7) · Infraestrutura & Instalação do Stack 23
 - Semana 2 (Dias 8 a 14) · Migração de Modelos LLM & Bases de Conhecimento 23
 - Semana 3 (Dias 15 a 21) · Migração de Agentes & Configuração de CI/CD 23
 - Semana 4 (Dias 22 a 30) · Virada de Chave Definitiva & Descomissionamento 23

Prefácio Executivo & Manifesto da Soberania

Dossiê completo de desmantelamento soberano para o Macro-Ecosistema Anthropic (Claude Code, Claude API, Model Context Protocol, AI Gateway e Managed Agents). Cada frente de desenvolvimento é estruturada com seu próprio Quinteto Soberano (A Mais Robusta, Mais Completa, Mais Moderna, Mais Leve e Mais Simples), acompanhada de análise de TCO, guias práticos de deploy, aderência white-label e ecossistema agêntico de MCPs nativos para integração.

A migração de suítes de software proprietário fechado para ecossistemas open source auto-hospedados em VPS representa a maior alavanca de eficiência operacional da década. Este livro-texto reúne as especificações de engenharia para desmantelar a suíte **Anthropic Claude API + Claude Code + MCP Protocol + AI Gateway + Managed Agents** com segurança jurídica, integridade de dados e autonomia digital irrestrita.

Capítulo 1: Engenharia Financeira, TCO Global & Payback

CUSTO SAAS ANUAL (Anthropic Claude API + Claude Code + MCP Protocol + AI Gateway + Managed Agents)

R\$ 156.000/ano (Anthropic API Tier Enterprise R\$ 84k + Claude Code licensing R\$ 48k + AI Gateway/Managed Agents R\$ 24k)

ECONOMIA LÍQUIDA ANUAL NO CAIXA

R\$ 151.800/ano (Economia Líquida de 97.3%)

- **Custo VPS Própria:** R\$ 4.200/ano (VPS 8 vCPU / 16 GB RAM a R\$ 350/mês em Hetzner Cloud) (Cluster Consolidado 8 vCPU / 16 GB RAM)
- **Retorno sobre Investimento (ROI / Payback):** Payback positivo em apenas 10 dias de operação unificada (VPS paga-se em 3-5 dias vs economia mensal).

Desmembramento Contábil por Frente de Negócio

Grupo	SaaS Alvo	Custo SaaS	Economia	Margem
Grupo 1: Orquestração & Agentes LLM	Anthropic Claude API + Managed Agents	R\$ 84.000/ano	R\$ 82.560/ano	98.3%
Grupo 2: Infraestrutura Dev & CI/CD	GitHub Enterprise + Docker Hub Private + CI/CD SaaS	R\$ 48.000/ano	R\$ 46.680/ano	97.2%
Grupo 3: Observabilidade & Monitoramento	DataDog / New Relic (Professional Tier)	R\$ 24.000/ano	R\$ 22.560/ano	94.0%

Capítulo 2: Infraestrutura Global, Dimensionamento da VPS & Provedores Validados

- **Perfil de Máquina Recomendado:** 8 vCPU / 16 GB RAM ECC / 160-240 GB NVMe
- **Racional de Engenharia:**

Provedores de Nuvem Recomendados & Custo Mensal

Provedor de Nuvem	Custo Mensal	Vantagem Principal & SLA
-------------------	--------------	--------------------------

Alocação Técnica de Recursos por Serviço (vCPU & RAM)

Serviço / Módulo	vCPU	RAM	Motivo Técnico & Gargalo
------------------	------	-----	--------------------------

Capítulo 3: Matriz Estratégica do Quinteto Soberano

Nº	Grupo	Persona	Ferramenta	Substitui	Economia
1	Grupo 1	Completa	Ollama	Anthropic Claude API (Tier Enterprise / Managed Agents)	R\$ 84.000/ano (Economia em API calls + Enterprise licen-sing)
2	Grupo 1	Robusta	LangChain	Anthropic Claude Code / Ma-naged Agents Runtime	R\$ 24.000/ano
3	Grupo 1	Moderna	LlamaIndex	Anthropic Claude Code / Knowledge Base Built-in	R\$ 18.000/ano
4	Grupo 1	Leve	Flowise	Anthropic Claude Code (Vi-sual Agent Builder)	R\$ 14.400/ano
5	Grupo 1	Simples	AnythingLLM	ChatGPT / Claude Cloud (Knowledge Base)	R\$ 12.000/ano
6	Grupo 2	Completa	Gitea	GitHub (Team Plan) / GitLab (Premium)	R\$ 24.000/ano (10 usuários)
7	Grupo 2	Robusta	Woodpecker CI	GitHub Actions / GitLab CI / Jenkins	R\$ 18.000/ano
8	Grupo 2	Moderna	MinIO	AWS S3 / Google Cloud Sto-rage	R\$ 12.000/ano
9	Grupo 2	Leve	Docker Registry	Docker Hub (Private Repos) / ECR / GCR	R\$ 9.600/ano
10	Grupo 2	Simples	Deno	Node.js (elimina dependên-cia de npm/package.json)	R\$ 6.000/ano
11	Grupo 3	Completa	Prometheus	DataDog / New Relic (Infras-structure Monitoring)	R\$ 24.000/ano
12	Grupo 3	Robusta	Grafana	DataDog / New Relic (Dash-boarding)	R\$ 18.000/ano
13	Grupo 3	Moderna	Loki	DataDog / Splunk / Elasticse-arch (Logging)	R\$ 14.400/ano
14	Grupo 3	Leve	Alertmanager	PagerDuty (Alert Routing)	R\$ 12.000/ano
15	Grupo 3	Simples	OpenTelemetry Col-lector	Datadog / New Relic / Sentry (Tracing & Collection)	R\$ 9.600/ano

Capítulo 3: Pilar 01 · Grupo 1: Orquestração de Agentes & Modelos LLM

Alvo SaaS Substituído: Anthropic Claude API + Claude Code + Managed Agents

Subtotal de Economia do Grupo: R\$ 156.000/ano

Frente responsável pela construção autônoma de agentes de IA, orquestração de modelos abertos, construção visual de workflows sem código e gerenciamento de memória de longo prazo (RAG).

01. Ollama · Executor Local de Modelos LLM Abertos (Llama 2, Mistral, Neural Chat) (Persona: Completa)

Substitui: Anthropic Claude API (Tier Enterprise / Managed Agents)

Economia: R\$ 84.000/ano (Economia em API calls + Enterprise licensing)

Licença: MIT

1. O Que Faz & Como Funciona:

Fornece CLI e servidor HTTP para executar modelos LLM abertos em uma única máquina ou cluster. Binário Go estático que compacta modelos em formato proprietário otimizado e executa inferência em paralelo com quantização.

```
ollama run mistral
```

2. Racional da Escolha & Veredito Técnico:

Permite rodar modelos de 7B a 70B parâmetros localmente com qualidade comparable aos modelos proprietários, eliminando dependência de API remota e acesso seguro a dados sensíveis.

Veredito: Substitui completamente a necessidade de chamadas remotas à Claude API para operações de raciocínio e geração de texto padrão.

3. Requisitos de Infraestrutura & White-Label:

- RAM Mínima: 8 GB RAM | CPU: 1 vCPU | Docker: oficial
- Customização UI: Serviço de backend puro sem UI, operando sob domínio corporativo (ex: llm.empresa.com.br). (Esforço: Baixo)

02. LangChain · Framework de Composição de Agentes, Chains & Memory para LLMs (Persona: Robusta)

Substitui: Anthropic Claude Code / Managed Agents Runtime

Economia: R\$ 24.000/ano

Licença: MIT

1. O Que Faz & Como Funciona:

Fornece abstrações Python e TypeScript para construir agentes de IA compostos com memory e tool calling. SDK Python/TypeScript com suporte nativo a chain execution, memory backends (Redis, PostgreSQL) e vector stores (Pinecone, Weaviate, Milvus).

```
pip install langchain && python -c "from langchain.chat_models import ChatOpenAI; chain = ..."
```

2. Racional da Escolha & Veredito Técnico:

Oferece abstrações robustas para construir agentes complexos sobre Ollama, OpenAI, Anthropic ou qualquer LLM, com suporte nativo a vector stores, caching e rastreamento de custos.

Veredito: Framework padrão de fato para desenvolvimento de agentes em produção, sustentado pela comunidade global e empresas como Stripe e Hugging Face.

3. Requisitos de Infraestrutura & White-Label:

- RAM Mínima: 2 GB RAM | CPU: 1 vCPU | Docker: oficial
- Customização UI: Totalmente customizável via código Python/TypeScript com suporte a prompts corporativos e personas de agentes. (Esforço: Baixo)

03. LlamaIndex · Framework de RAG (Retrieval-Augmented Generation) com Vector Stores (Persona: Moderna)

Substitui: Anthropic Claude Code / Economia: R\$ 18.000/ano

Licença: MIT

Knowledge Base Built-in

1. O Que Faz & Como Funciona:

Ingere documentos, cria índices vetoriais e recupera contexto relevante para agentes consultarem bases de conhecimento. SDK Python com suporte a loaders de múltiplos formatos (PDF, Docx, HTML) e integração com vector stores (Pinecone, Weaviate, Chroma).

```
pip install llama-index && from llama_index import GPTVectorStoreIndex, SimpleDirectoryReader
```

2. Racional da Escolha & Veredito Técnico:

Indexação automática de PDFs, markdowns e bases de dados com chunking inteligente e reranking para recuperação precisa de contexto.

Veredito: Padrão de fato para RAG, usado por startups de AI e enterprises para document QA e knowledge discovery.

3. Requisitos de Infraestrutura & White-Label:

- RAM Mínima: 2 GB RAM | CPU: 1 vCPU | Docker: oficial
- Customização UI: Customização total de prompts de retrieval e parsing de documentos. (Esforço: Baixo)

04. Flowise · Construtor Visual Drag-and-Drop de Workflows de IA (Persona: Leve)

Substitui: Anthropic Claude Code Economia: R\$ 14.400/ano

Licença: Apache-2.0

(Visual Agent Builder)

1. O Que Faz & Como Funciona:

Cria workflows de IA complexos arrastando nós de modelos, tools e lógica condicional. Node.js e React com execução de workflows em background via Bull Queue.

```
npm install -g flowise && flowise start
```


2. Racional da Escolha & Veredito Técnico:

Oferece editor visual parecido com Make/Zapier especialmente otimizado para LLMs, com suporte a Ollama, OpenAI e Anthropic.

Veredito: *Melhor solução visual para prototipagem rápida de agentes complexos com múltiplas integrações.*

3. Requisitos de Infraestrutura & White-Label:

- RAM Mínima: 2 GB RAM | CPU: 1 vCPU | Docker: oficial
- Customização UI: Workflows completamente customizáveis com suporte a prompts corporativos. (Esforço: Baixo)

05. AnythingLLM · RAG Platform All-in-One com Chat Interface (Persona: Simples)

Substitui: ChatGPT / Claude Cloud
(Knowledge Base)

Economia: R\$ 12.000/ano

Licença: MIT

1. O Que Faz & Como Funciona:

Cria um sistema de chat que responde perguntas sobre documentos corporativos uploadados. Binário Go estático com SQLite embarcado e embeddings locais via Ollama.

```
docker run -d -p 3001:3001 --name anythingllm mintplexlabs/anythingllm:latest
```

2. Racional da Escolha & Veredito Técnico:

Single-binary Go que encapsula Ollama, vector store, chunking e UI de chat em uma solução zero-dependencies.

Veredito: *A forma mais rápida e simples de deployar um knowledge base corporativo sem conhecimento técnico.*

3. Requisitos de Infraestrutura & White-Label:

- RAM Mínima: 4 GB RAM | CPU: 1 vCPU | Docker: oficial
- Customização UI: White-label completo com logo e cores corporativas. (Esforço: Baixo)

Capítulo 4: Pilar 02 · Grupo 2: Infraestrutura de Desenvolvimento, CI/CD & Versionamento

Alvo SaaS Substituído: [GitHub](#) / [GitLab](#) / [Claude Code \(IDE Integration\)](#) / [GitHub Actions](#)

Subtotal de Economia do Grupo: R\$ 60.000/ano

Frente responsável pela gestão de código-fonte distribuído, automação de builds e testes, registro de imagens Docker e orquestração de pipelines de deployment.

01. Gitea · Servidor Git Auto-Hospedado Leve com Interface Web (Persona: Completa)

Substitui: [GitHub \(Team Plan\)](#) / [GitLab \(Premium\)](#)

Economia: **R\$ 24.000/ano** (10 usuários)

Licença: MIT

1. O Que Faz & Como Funciona:

Fornece servidor Git completo com interface web para gerenciar repositórios e colaboração. Binário Go estático sobre SQLite ou PostgreSQL com suporte a organizações e equipes.

`docker run -d -p 3000:3000 --name gitea gitea/gitea:latest`

2. Racional da Escolha & Veredito Técnico:

Binário Go ultra-leve que substitui GitHub em 100% dos casos, com suporte a webhooks, integração SSH/HTTPS e pull requests nativas.

Veredito: *GitHub/GitLab on-premises mais simples e rápido de operar em produção, consumindo menos de 100 MB RAM.*

3. Requisitos de Infraestrutura & White-Label:

- RAM Mínima: 2 GB RAM | CPU: 1 vCPU | Docker: oficial
- Customização UI: Logo corporativa e domínio próprio (ex: `git.empresa.com.br`). (Esforço: Baixo)

02. Woodpecker CI · Motor de CI/CD Moderno com Suporte a Containers & Kubernetes (Persona: Robusta)

Substitui: [GitHub Actions](#) / [GitLab CI](#) / [Jenkins](#)

Economia: **R\$ 18.000/ano**

Licença: Apache-2.0

1. O Que Faz & Como Funciona:

Executa pipelines de build, teste e deploy em containers Docker isolados disparados por push/PR. Go + Docker API com suporte a segredos e variáveis de ambiente criptografadas.

`docker run -d -p 8000:8000 --name woodpecker woodpeckerci/woodpecker-server:latest`

2. Racional da Escolha & Veredito Técnico:

Alternativa moderna a Jenkins com suporte nativo a Docker, Kubernetes e pipelines YAML declarativas aprovadas no

Gitea.

Veredito: Substituição direta de GitHub Actions com melhor experiência operacional e logs de pipeline.

3. Requisitos de Infraestrutura & White-Label:

- RAM Mínima: 2 GB RAM | CPU: 1 vCPU | Docker: oficial
- Customização UI: Pipelines totalmente customizáveis em YAML com suporte a secrets corporativos. (Esforço: Baixo)

03. MinIO · Object Storage S3-Compatible para Artefatos & Backups (Persona: Moderna)

Substitui: AWS S3 / Google Cloud Storage

Economia: R\$ 12.000/ano

Licença: AGPL-3.0

1. O Que Faz & Como Funciona:

Fornece armazenamento de objetos escalável com API S3-compatible. Binário Go com suporte a multi-node clustering e replicação.

```
docker run -d -p 9000:9000 --name minio minio/minio:latest server /data
```

2. Racional da Escolha & Veredito Técnico:

API 100% compatível com S3 permitindo trocar de fornecedor sem mudança de código, com suporte a replicação geo-distribuída.

Veredito: S3 local com performance igual ou superior, eliminando vendor lock-in.

3. Requisitos de Infraestrutura & White-Label:

- RAM Mínima: 1 GB RAM | CPU: 1 vCPU | Docker: oficial
- Customização UI: Interface web customizável com suporte a SSO OIDC. (Esforço: Baixo)

04. Docker Registry · Registro Privado de Imagens Docker (Persona: Leve)

Substitui: Docker Hub (Private Repos) / ECR / GCR

Economia: R\$ 9.600/ano

Licença: Apache-2.0

1. O Que Faz & Como Funciona:

Fornece repositório centralizado de imagens Docker com autenticação básica. Go com armazenamento em filesystem ou object storage S3 (MinIO).

```
docker run -d -p 5000:5000 --name registry registry:2
```

2. Racional da Escolha & Veredito Técnico:

Registrador oficial da Docker focado em performance e simplicidade, com suporte a pull/push sobre HTTPS TLS.

Veredito: Registro Docker leve e confiável para equipes pequenas até médias.

3. Requisitos de Infraestrutura & White-Label:

- RAM Mínima: 1 GB RAM | CPU: 1 vCPU | Docker: oficial
- Customização UI: Serviço puro de backend sem UI. (Esforço: Baixo)

05. Deno · Runtime JavaScript/TypeScript Moderno com Permissões Granulares (Persona: Simples)

Substitui: Node.js (elimina dependência de npm/package.json)

Economia: R\$ 6.000/ano

Licença: MIT

1. O Que Faz & Como Funciona:

Executa scripts TypeScript/Javascript com controle fino de permissões (arquivo, rede, variáveis de ambiente). Binário Rust estático com bundler integrado e cache imutável via URLs.

```
deno run --allow-net https://deno.land/std/examples/echo_server.ts
```

2. Racional da Escolha & Veredito Técnico:

Runtime TypeScript nativo com URLs imutáveis, sem arquivo package.json e permissões explícitas, reduzindo risco de supply chain.

Veredito: Excelente para scripts de automação corporativa sem risco de supply chain (sem node_modules).

3. Requisitos de Infraestrutura & White-Label:

- RAM Mínima: 256 MB RAM | CPU: 1 vCPU | Docker: oficial
- Customização UI: Scripts totalmente customizáveis em TypeScript puro. (Esforço: Baixo)

Capítulo 5: Pilar 03 · Grupo 3: Observabilidade, Monitoramento & Suporte

Alvo SaaS Substituído: [DataDog](#) / [New Relic](#) / [Sentry \(Error Tracking\)](#) / [PagerDuty](#)

Subtotal de Economia do Grupo: **R\$ 48.000/ano**

Frente responsável pela coleta de métricas, logs e traces distribuídos, alertas proativos e análise de performance em tempo real.

01. Prometheus · Time-Series Database & Scraper de Métricas (Persona: Completa)

Substitui: DataDog / New Relic (Infrastructure Monitoring)	Economia: R\$ 24.000/ano	Licença: Apache-2.0
--	---------------------------------	-------------------------------------

1. O Que Faz & Como Funciona:

Scrape de endpoints `/metrics` em intervalos regulares, armazenando séries temporais e fornecendo SQL-like PromQL. Binário Go estático com armazenamento em disco local e compressão de dados.

```
docker run -d -p 9090:9090 --name prometheus prom/prometheus
```

2. Racional da Escolha & Veredito Técnico:

Padrão de fato do CNCF para observabilidade em Kubernetes e containers, com pull-based scraping nativo.

Veredito: Substituição completa de [DataDog](#)/[New Relic](#) para equipes que não precisam de observabilidade SaaS.

3. Requisitos de Infraestrutura & White-Label:

- RAM Mínima: 2 GB RAM | CPU: 1 vCPU | Docker: oficial
- Customização UI: Totalmente customizável via YAML e PromQL. (Esforço: Baixo)

02. Grafana · Plataforma de Dashboards & Alertas para Observabilidade (Persona: Robusta)

Substitui: DataDog / New Relic (Dashboarding)	Economia: R\$ 18.000/ano	Licença: AGPL-3.0 (Enterprise: Proprietary)
---	---------------------------------	---

1. O Que Faz & Como Funciona:

Constrói dashboards interativos consumindo dados de Prometheus, Loki e outras fontes. Go backend com React frontend e suporte a plugins customizados.

```
docker run -d -p 3000:3000 --name grafana grafana/grafana
```

2. Racional da Escolha & Veredito Técnico:

Dashboard builder visual mais poderoso, suportando Prometheus, Loki, Elasticsearch e 100+ data sources.

Veredito: Melhor dashboard open source do mercado, com UX comparável a SaaS premium.

3. Requisitos de Infraestrutura & White-Label:

- RAM Mínima: 1 GB RAM | CPU: 1 vCPU | Docker: oficial

- Customização UI: White-label completo com logo e domínio corporativo. (Esforço: Baixo)

03. Loki · Log Aggregation System com Índices Otimizados (Persona: Moderna)

Substitui: DataDog / Splunk / Elasticsearch (Logging)

Economia: R\$ 14.400/ano

Licença: AGPL-3.0

1. O Que Faz & Como Funciona:

Ingere logs de containers, estrutura-os por labels e fornece buscas rápidas com LogQL. Go com armazenamento em S3 (MinIO) e índices em memória.

```
docker run -d -p 3100:3100 --name loki grafana/loki
```

2. Racional da Escolha & Veredito Técnico:

Alternativa leve ao Elasticsearch reduzindo em 10x o storage necessário via índices inteligentes baseados em labels.

Veredito: Alternativa superior ao ELK stack para organismos não-gigantes, com 90% menos storage.

3. Requisitos de Infraestrutura & White-Label:

- RAM Mínima: 2 GB RAM | CPU: 1 vCPU | Docker: oficial
- Customização UI: Totalmente customizável via YAML. (Esforço: Baixo)

04. Alertmanager · Gerenciador de Alertas & Deduplicação (Persona: Leve)

Substitui: PagerDuty (Alert Routing)

Economia: R\$ 12.000/ano

Licença: Apache-2.0

1. O Que Faz & Como Funciona:

Agrupa alertas similares, deduplica e envia notificações via múltiplos canais. Go com armazenamento em memória e replicação opcional.

```
docker run -d -p 9093:9093 --name alertmanager prom/alertmanager
```

2. Racional da Escolha & Veredito Técnico:

Complemento oficial ao Prometheus com suporte a grouping, silenciamento e escalonamento de alertas.

Veredito: Essential companion ao Prometheus para evitar alertas repetitivos.

3. Requisitos de Infraestrutura & White-Label:

- RAM Mínima: 512 MB RAM | CPU: 1 vCPU | Docker: oficial
- Customização UI: Templates de notificação customizáveis. (Esforço: Baixo)

05. OpenTelemetry Collector · Coleta & Processamento Agnóstico de Traces, Métricas & Logs (Persona: Simples)

Substitui: Datadog / New Relic / Sentry (Tracing & Collection)

Economia: R\$ 9.600/ano

Licença: Apache-2.0

1. O Que Faz & Como Funciona:

Coleta traces, métricas e logs em formato OpenTelemetry e exporta para múltiplos backends. Go com suporte a OTLP protocol e receiverexportadores plugáveis.

```
docker run -d -p 4317:4317 -p 4318:4318 --name otel-collector otel/opentelemetry-collector
```

2. Racional da Escolha & Veredito Técnico:

Padrão CNCF agnóstico de backend, permitindo enviar dados para Prometheus, Loki, Jaeger ou qualquer sistema sem reescrever código.

Veredito: *Agnóstico de backend ideal para evitar lock-in em uma solução comercial.*

3. Requisitos de Infraestrutura & White-Label:

- RAM Mínima: 1 GB RAM | CPU: 1 vCPU | Docker: oficial
- Customização UI: Totalmente customizável via YAML. (Esforço: Baixo)

Capítulo 6: Camada de Cola, SSO Federado & Blueprints n8n

Arquitetura de Interconexão sem Silos de Dados

- **Autenticação Única:** Keycloak / Authentik (OpenID Connect / SAML) unificando o login de engenheiros e agentes de IA no Gitea, Woodpecker, Grafana, Ollama Web UI e Flowise.
- **Barramento Assíncrono:** n8n Community Edition atuando como orquestrador central de eventos assíncronos (Build concluído no Woodpecker -> Modelo treinado no Ollama -> Teste executado em LlamaIndex -> Alerta enviado no Slack via Alertmanager).
- **Reverse Proxy & TLS:** Traefik Proxy v3 com terminação TLS automática via Let's Encrypt e roteamento por subdomínios corporativos (git.empresa.com.br, ci.empresa.com.br, llm.empresa.com.br, obs.empresa.com.br, sso.empresa.com.br).

Fluxo de Integração Operacional

1. Commit de Código: Engenheiro faz push no Gitea;
2. Trigger CI/CD: Webhook dispara no Woodpecker que executa testes e builds;
3. Artefatos: Build artifacts são armazenados no MinIO e imagem Docker no Registry privado;
4. Deploy de Agentes: n8n dispara o deploy dos novos agentes LLM via Flowise/LangChain;
5. Testes de Agente: LangChain executa testes de agente consultando Ollama local e LlamaIndex;
6. Observabilidade: Prometheus coleta métricas de latência do agente, Loki ingere logs de erro, Alertmanager notifica no Slack;
7. Feedback Loop: Agentes consultam Grafana para decidir se retrainam ou escalam.

Capítulo 7: Manual de Engenharia de Infraestrutura & Deploy All-in-One

- **Segurança de Rede:** A infraestrutura opera sobre uma rede bridge isolada do Docker (ai_ecosystem_net). Apenas o reverse proxy Traefik expõe as portas públicas 80 (HTTP com redirect) e 443 (HTTPS TLS automático via ACME/Let's Encrypt). Todas as ferramentas (Ollama, LangChain, Flowise, Gitea, Woodpecker, Prometheus, Grafana, Loki e Keycloak) comunicam-se exclusivamente pela rede interna através de seus nomes DNS de serviço, eliminando vetores de ataque externos.
- **Perfil de VPS Recomendado:** 8 vCPU / 16 GB RAM

Especificação da VPS Ideal (e Por Que Desta Configuração)

Serviço / Módulo	vCPU	RAM	Motivo Técnico & Gargalo
------------------	------	-----	--------------------------

Manifesto docker-compose.yml de Produção

```
version: '3.8'

networks:
  ai_ecosystem_net:
    driver: bridge

services:
  # 1. Reverse Proxy & TLS Automático
  traefik:
    image: traefik:v3.0
    command:
      - '--providers.docker=true'
      - '--entrypoints.web.address=:80'
      - '--entrypoints.websecure.address=:443'
      - '--certificatesresolvers.myresolver.acme.tlschallenge=true'
      - '--certificatesresolvers.myresolver.acme.email=admin@empresa.com'
      - '--certificatesresolvers.myresolver.acme.storage=/letsencrypt/acme.json'
    ports:
      - '80:80'
      - '443:443'
    volumes:
      - '/var/run/docker.sock:/var/run/docker.sock:ro'
      - './letsencrypt:/letsencrypt'
    networks:
      - ai_ecosystem_net
```

2. Ollama LLM Server

```
ollama:
  image: ollama/ollama:latest
  environment:
    - OLLAMA_HOST=0.0.0.0:11434
  volumes:
    - ollama_data:/root/.ollama
  networks:
    - ai_ecosystem_net
```

3. Flowise AI Builder

```
flowise:
  image: flowiseai/flowise:latest
  ports:
    - '3001:3001'
  volumes:
    - flowise_data:/root/.flowise
  labels:
    - 'traefik.enable=true'
    - 'traefik.http.routers.flowise.rule=Host(`ai-builder.empresa.com.br`)'
  networks:
    - ai_ecosystem_net
```

4. Gitea Repository

```
gitea:
  image: gitea/gitea:latest
  labels:
    - 'traefik.enable=true'
    - 'traefik.http.routers.gitea.rule=Host(`git.empresa.com.br`)'
  volumes:
    - gitea_data:/data
  networks:
    - ai_ecosystem_net
```

5. Woodpecker CI

```
woodpecker-server:
  image: woodpeckerci/woodpecker-server:latest
  labels:
    - 'traefik.enable=true'
    - 'traefik.http.routers.woodpecker.rule=Host(`ci.empresa.com.br`)'
  networks:
    - ai_ecosystem_net
```

6. Prometheus Metrics

```
prometheus:  
  image: prom/prometheus:latest  
  ports:  
    - '9090:9090'  
  volumes:  
    - prometheus_data:/prometheus  
  networks:  
    - ai_ecosystem_net
```

7. Grafana Dashboards

```
grafana:  
  image: grafana/grafana:latest  
  labels:  
    - 'traefik.enable=true'  
    - 'traefik.http.routers.grafana.rule=Host(`monitoring.empresa.com.br`)'  
  volumes:  
    - grafana_data:/var/lib/grafana  
  networks:  
    - ai_ecosystem_net
```

```
volumes:  
  ollama_data:  
  flowise_data:  
  gitea_data:  
  prometheus_data:  
  grafana_data:
```

Capítulo 8: Protocolos de Modularidade & Hot-Swap (Princípio do Lego)

- **Filosofia Desacoplada:** A arquitetura opera sob o princípio de 'Tomadas e Aparelhos Independentes'. Nenhuma ferramenta fica grudada ou dependente da outra com código travado. Imagine uma régua de tomadas: Ollama (LLM) e LangChain (Framework) funcionam perfeitamente mesmo se você desligar Flowise (Builder). Se quiser trocar Ollama por outro LLM, basta desconectar e plugar o novo. Nada quebra.

Hot-Swap em Produção

1. Suba a Nova Ferramenta em Paralelo: Inicie a nova solução em um endereço temporário (ex: novo-llm.empresa.com.br) mantendo a antiga funcionando;
2. Transfira a Conexão em Flowise/LangChain: No painel visual, mude o nó de conexão para apontar para a nova ferramenta;
3. Importe Configurações: Faça o download dos workflows/modelos da ferramenta antiga e importe na nova;
4. Mude o Endereço Oficial: Altere a rota para que llm.empresa.com.br aponte para a nova ferramenta;
5. Desligue a Antiga com Segurança: Pare o serviço antigo digitando `docker compose stop <servico\_antigo>`. Os seus agentes nem notarão a troca!

Capítulo 9: Roteiro Prático de Migração de Dados Históricos

1. Migração de Agentes de Claude Code para Stack Aberto

- **O que migrar:** Configurações de agentes, prompts base, MCP servers registrados, histórico de conversas e modelos treinados.
- **Cuidados:** Preserve a lógica de fallback para garantir que agentes funcionem tanto localmente quanto com API remota.

2. Migração de Knowledge Bases (RAG) para LlamaIndex

- **O que migrar:** Documentações, PDFs treinados, embeddings vetoriais e configurações de retrieval.
- **Cuidados:** Teste a qualidade de retrieval com queries conhecidas antes de descomissionar a base antiga.

3. Migração de Pipelines CI/CD de GitHub Actions para Woodpecker

- **O que migrar:** Workflows de teste, build e deploy, secrets e variáveis de ambiente.
- **Cuidados:** Mantenha GitHub Actions ativo por uma semana em paralelo para contingência.

Capítulo 10: Governança Corporativa, Backup 3-2-1 & LGPD

- **Política 3-2-1:** A política de proteção de dados opera na regra de ouro 3-2-1: (3) cópias de dados em (2) tipos de mídias diferentes, com (1) cópia externa criptografada em nuvem fria (Wasabi / AWS S3).

Script de Backup Diário Criptografado

```
#!/bin/bash

TIMESTAMP=$(date +"%Y%m%d_%H%M%S")
BACKUP_DIR="/opt/backups/$TIMESTAMP"
mkdir -p $BACKUP_DIR

# 1. Dump de todos os bancos (Keycloak, Gitea, Woodpecker)
docker exec postgres pg_dumpall -U postgres | gzip > $BACKUP_DIR/db_cluster.sql.gz

# 2. Compactação dos modelos Ollama e configurações
tar -czf $BACKUP_DIR/ollama_models.tar.gz -C /var/lib/docker/volumes ollama_data/_data

# 3. Criptografia AES-256
gpg --batch --yes --passphrase "SenhaChaveMestreSegura2026" -c $BACKUP_DIR/db_cluster.sql.gz

# 4. Envio para Storage Externo via rclone
rclone copy $BACKUP_DIR remote-s3:backups-empresa/$TIMESTAMP/

# 5. Limpeza de backups locais com mais de 7 dias
find /opt/backups/* -mtime +7 -exec rm -rf {} \;
echo "Backup soberano concluído!"
```

Capítulo 11: Cronograma de Implantação em 30 Dias & Monitoramento

Semana 1 (Dias 1 a 7) · Infraestrutura & Instalação do Stack

- **Atividades:** Contratação da VPS, configuração de DNS wildcard, execução do docker-compose.yml e ativação de certificados SSL automáticos via Traefik.
- **Marco de Entrega:** None

Semana 2 (Dias 8 a 14) · Migração de Modelos LLM & Bases de Conhecimento

- **Atividades:** Download de modelos Ollama (Mistral 7B, Llama 2), indexação de documentação corporativa em LlamaIndex e teste de inference local.
- **Marco de Entrega:** None

Semana 3 (Dias 15 a 21) · Migração de Agentes & Configuração de CI/CD

- **Atividades:** Migração de agentes de Claude Code, configuração de pipelines Woodpecker e workshop de capacitação das equipes de desenvolvimento.
- **Marco de Entrega:** None

Semana 4 (Dias 22 a 30) · Virada de Chave Definitiva & Descomissionamento

- **Atividades:** Redirecionamento de endpoints de API para stack local, ativação de observabilidade integrada (Prometheus + Grafana) e cancelamento de faturas Anthropic.
- **Marco de Entrega:** None